

10주차 발표자료 요약본

토큰화

- 토큰화: 자연어 처리 모델을 만들기 위해 말뭉치(대규모의 자연어)를 토큰(개별 단어나 문장 부호화 같은 텍스트)로 나누는 과정
- 토큰화는 토큰라이저를 통해 수행한다

토큰라이저를 구축하는 다양한 방법

- 공백 분할, 정규 표현식 적용, 어휘사전, 머신러닝 활용

→ 이런 다양한 구축 방법이 시스템의 성능/처리 결과에 큰 영향을 줌

단어 및 글자 토큰화

단어 토큰화

- 텍스트 데이터 → 단어 분리 작업
- 핵심 전처리 작업 중 하나
- 사용되는 분야 : 품사 태깅, 개체명 인식, 기계 번역 등

글자 토큰화

- 글자 단위로 문장을 나누는 방식
- 언어 모델링과 같은 시퀀스 예측 작업에서 활용
- 단점:
 - 다의어나 동음이의어가 많은 도메인에서 구별이 어렵고 입력이 길어질수록 연산량 증가

형태소 토큰화

- 텍스트를 형태소 단위로 나누는 토큰화 방법
- 언어의 문법과 구조를 고려해 단어를 분리하고 의미 있는 단위로 분류

형태소 어휘 사전

- 각 단어의 형태소 정보를 포함하는 사전으로, 단어가 어떤 형태소들의 조합으로 이루어져 있는지에 대한 정보를 담고 있음.

하위단어 토큰화

기존 형태소 분석기는 어휘 사전에 없는 새로운 단어에 대해서는 취약하다는 단점이 있었다.

⇒ 자주 함께 나타나는 문자열을 묶어 서브워드 단위로 모델링하는 새로운 방법을 제시하여 OOV 감소, 어휘 축소 등의 효과를 얻을 수 있었다.

Byte Pair Encoding

- 문자 단위로 시작 → 가장 자주 출현하는 인접 쌍 병합 반복
- 특징: 빈도 기반, 간단하고 효율적, 신어 일반화 강함

토큰나이저 학습 공통 프로세스

1. 데이터 수집: 도메인 대표성/크기/클린
2. 정규화: lowercasing, NFD/NFKC, 특수문자 규칙
3. 프리토큰화: 공백/ByteLevel/Metaspaces 등
4. 모델 학습: BPE/WordPiece/Unigram, vocab 크기 결정
5. 포스트프로세싱: [CLS]/[SEP] 삽입 등 템플릿 처리
6. 평가: 토큰 길이, 커버리지, OOV, Perplexity 대리 지표
7. 저장/배포: 버전 고정, 재현성/호환성 체크

임베딩

- 텍스트 벡터화: 컴퓨터가 이해할 수 있도록 텍스트를 숫자로 변환하는 과정
- 원핫인코딩: 각 단어를 고유한 색인 값으로 매핑 후 해당 색인 위치는 1, 나머지는 0으로 표시하는 방법
- 빈도벡터화: 문서에서 단어의 빈도수를 세어 해당 단어의 빈도를 벡터로 표현하는 방법
 - 장점: 벡터형태로 변환이 쉬움
 - 단점: 벡터의 희소성이 큼 → 차원의 저주 문제 발생, 텍스트의 의미 반영X

워드 임베딩

- 단어를 고정된 길이의 실수 벡터로 표현 → 단어의 의미를 상대적 위치로 표현해 단어 간 관계 추론 (ex. Word2Vec, fastText)
- 단점: 다의어나 문맥 정보를 다루기 어려움 → **동적 임베딩**으로 해결

언어 모델

- 입력된 문장으로 문맥을 이해하고 예측을 수행하는 모델

자기회귀 언어 모델

- 조건부 확률을 이용해 다음에 올 단어 예측
- 조건부 확률의 연쇄 법칙 적용 → 문장 전체의 확률을 계산하고 그를 이용해 다음 단어 예측

통계적 언어 모델

- 언어의 통계적 구조를 이용해 시퀀스에 대한 확률 분포를 추정하는 방식으로 문맥을 파악해 다음에 등장할 단어의 확률 예측

N-gram

- 텍스트에서 N개의 연속된 단어 시퀀스를 하나의 단어로 취급하여 특정 단어 시퀀스가 등장할 확률 추정
- n값에 따라 유니그램(1), 바이그램(2), 트라이그램(3), N-gram($n \geq 4$)

TF-IDF

- 텍스트 문서에서 BoW에 가중치를 부여하여 특정 단어의 중요도를 계산하는 방법

BoW

- 문서/문장에 등장하는 단어의 중복을 허용해 단어의 집합으로 문서나 문장을 표현함

	TF	DF	IDF
명칭	단어 빈도	문서 빈도	열문서 빈도
의미	문서 내에서 특정 단어의 빈도수 나타냄	한 단어가 얼마나 많은 문서에 나타나는지	문서 내에서 특정 단어가 얼마나 중요한지

	TF	DF	IDF
큰 값이 지니는 의미	특정 문서에서 중요한 역할 → 전문 용어나 관용어	일반적으로 널리 사용되는 단어 → 중요도 낮음	일반적이고 중요X

- TF-IDF : $TF \times IDF$
 - 관사/관용어 등의 가중치 낮아짐

TF-IDF의 한계점

- 문맥과 단어 순서 고려X
- 단어의 의미 반영X